

Exercices

Exercice 1 Box-Muller and Marsaglia-Bray algorithm

1. On se donne une fonction h qu'on suppose continue et bornée. Si on peut montrer (1) avec f_X et f_Y des densités gaussiennes centrées réduites, alors on aura montré que X et Y sont indépendantes et suivent une loi normale centrée réduite par le théorème d'identification des lois.

$$\forall h \quad \mathbb{E}[h(X, Y)] = \int_{\mathbb{R}^2} h(x, y) f_X(x) f_Y(y) dx dy \quad (1)$$

Soit h continue et bornée.

$$\begin{aligned} \mathbb{E}[h(R \cos \Theta, R \sin \Theta)] &= \int_{\mathbb{R}^2} h(r \cos \theta, r \sin \theta) f_{R, \Theta}(r, \theta) dr d\theta \\ &= \int_{\mathbb{R}^+} \int_0^{2\pi} \frac{h(r \cos \theta, r \sin \theta)}{2\pi} r \exp\left(\frac{-r^2}{2}\right) dr d\theta = (*) \end{aligned}$$

Soit $\Psi : (r, \theta) \mapsto (x, y)$. Ψ est un \mathcal{C}^1 -difféomorphisme (bijection différentiable) de $\mathbb{R}^+ \times [0, 2\pi]$ dans \mathbb{R}^2 . On a :

$$\begin{aligned} \nabla \Psi &= \begin{pmatrix} \frac{\partial x}{\partial r} & \frac{\partial x}{\partial \theta} \\ \frac{\partial y}{\partial r} & \frac{\partial y}{\partial \theta} \end{pmatrix} \\ &= \begin{pmatrix} \cos \theta & -r \sin \theta \\ \sin \theta & r \cos \theta \end{pmatrix} \end{aligned}$$

De plus $\det(\nabla \Psi) = r \cos^2 \theta + r \sin^2 \theta = r$. Par le théorème de changement de variable :

$$\begin{aligned} (*) &= \int_{\mathbb{R}^2} h(x, y) \exp\left(\frac{-(x^2 + y^2)}{2}\right) \frac{1}{2\pi} dx dy \\ &= \int_{\mathbb{R}^2} h(x, y) \frac{\exp(-x^2/2)}{\sqrt{2\pi}} \frac{\exp(-y^2/2)}{\sqrt{2\pi}} dx dy \end{aligned}$$

On a montré (1), donc $\boxed{X, Y \sim \mathcal{N}(0, 1) \text{ et sont indépendantes}}.$

2. Écrire un algorithme pour échantillonner (sampler) deux gaussiennes indépendantes de loi $\mathcal{N}(0, 1)$.

Rappel (Théorème de la transformée inverse)

Soit $U \sim \mathcal{U}([0, 1])$ et soit X une variable aléatoire qui a pour fonction de répartition F telle que $F(x) = \int_{-\infty}^x f_X(x) dx$. Alors $F^{-1}(U) \sim X$.

La fonction de répartition de la loi de Rayleigh de paramètre 1 est :

$$\begin{aligned} F_R(r) &= \int_0^r t \exp(-t^2/2) dt \\ &= [-\exp(-t^2/2)]_0^r \\ &= 1 - \exp(-r^2/2) \end{aligned}$$

Par le théorème de la transformée inverse, $F_R^{-1}(U) \sim R(1)$. $F_R : \mathbb{R} \rightarrow [0, 1]$ est monotone et continue sur un intervalle fermé. Soit $y \in [0, 1]$ tel que $y = F_R(r)$.

$$\begin{aligned} y = F_R(r) &\Leftrightarrow y = 1 - \exp(-r^2/2) \\ &\Leftrightarrow \exp(-r^2/2) = 1 - y \\ &\Leftrightarrow -r^2/2 = \ln(1 - y) \\ &\Leftrightarrow r^2 = -2 \ln(1 - y) \\ &\Leftrightarrow \boxed{r = \sqrt{-2 \ln(1 - y)}} \quad \text{car } y \in [0, 1]. \end{aligned}$$

On en déduit l'algorithme suivant :

Algorithme :

1. Tirer U_1, U_2 de loi uniforme sur $[0, 1]$.
2. Prendre $R = -\sqrt{2 \log(1 - U_1)}$ et $\Theta = 2\pi U_2$. R suit une loi de Rayleigh de paramètre 1 et Θ suit une loi uniforme sur $[0, 2\pi]$.
3. Prendre $(X, Y) = (R \cos(\Theta), R \sin(\Theta))$. D'après la question 1., X et Y sont indépendantes et suivent une loi $\mathcal{N}(0, 1)$.

3. a) À la fin de la boucle (V_1, V_2) suivent la distribution uniforme de :

$$E = \{(V_1, V_2) | V_1^2 + V_2^2 \leq 1\}$$

(V_1, V_2) a pour densité :

$$\begin{aligned} f_{V_1, V_2}(v_1, v_2) &= \frac{1}{|E|} \mathbb{1}_{\{v_1^2 + v_2^2 \leq 1\}}(v_1, v_2) \mathbb{1}_{[-1, 1]^2}(v_1, v_2) \\ &= \boxed{\frac{1}{\pi} \mathbb{1}_{\{v_1^2 + v_2^2 \leq 1\}}(v_1, v_2)} \end{aligned}$$

b) On utilise à nouveau le théorème d'identification des lois. Soit h continue et bornée. On veut montrer que :

$$\mathbb{E}[h(T_1, V)] = \int h(t_1, v) f_{T_1}(t_1) f_V(v) dv dt_1$$

avec f_{T_1} et f_V les densités qui nous intéressent.

Distribution de $\cos(\Theta)$:

Soit $\Theta \sim \mathcal{U}([0, 2\pi])$. On note que $\cos([0, \pi]) = \cos([\pi, 2\pi])$. Par conséquent travaillons avec $Y = \cos(\Theta/2)$ afin d'avoir une fonction monotone et inversible. On cherche la densité de Y .

$$\begin{aligned} F_Y(y) &= P(Y \leq y) \\ &= P(\cos(\Theta/2) \leq y) \\ &= P(\Theta/2 \geq \arccos(y)) \\ &= P(\Theta/2 \leq \arccos(-y)) \\ &= \arccos(-y)/\pi \\ f_Y(y) &= \frac{d}{dy} F_Y(y) \\ &= \frac{1}{\pi} \frac{d}{dy} \arccos(-y) \\ &= \boxed{\frac{1}{\pi \sqrt{1-y^2}}} \end{aligned}$$

Distribution de T_1 :

On note $\Psi : v_1, v_2 \mapsto (t_1, v)$. On note que ψ n'est pas injective. Calculons le jacobien de Ψ :

$$\begin{aligned} \nabla \Psi &= \begin{pmatrix} \frac{\partial t_1}{\partial v_1} & \frac{\partial t_1}{\partial v_2} \\ \frac{\partial v}{\partial v_1} & \frac{\partial v}{\partial v_2} \end{pmatrix} \\ &= \begin{pmatrix} \frac{v_2^2}{(v_1^2 + v_2^2)^{3/2}} & \frac{-v_1 v_2}{(v_1^2 + v_2^2)^{3/2}} \\ 2v_1 & 2v_2 \end{pmatrix} \end{aligned}$$

On a donc le jacobien $\det \nabla \Psi = \frac{2v_2}{\sqrt{v_1^2 + v_2^2}} = 2\sqrt{1 - t_1^2}$. Par le théorème de changement de variable :

$$\begin{aligned} &\int_{-1}^1 \int_{-1}^1 h(t_1(v_1, v_2), v(v_1, v_2)) \frac{1}{\pi} \mathbb{1}_{\{v_1^2 + v_2^2 \leq 1\}}(v_1, v_2) dv_1 dv_2 \\ &= 2 \int_{-1}^1 \int_0^1 h(t_1, v) \mathbb{1}_{\{v \leq 1\}} \frac{1}{2\pi \sqrt{1 - t_1^2}} dv dt_1 \end{aligned} \quad \begin{array}{l} \text{(le facteur 2 provient de} \\ \text{la non-injectivité de } \Psi \text{).} \end{array}$$

On reconnaît bien la densité de $\cos(\Theta)$ et celle de $\mathcal{U}([0, 1])$. Donc T_1 et V sont indépendantes, T_1 suit la même distribution que $\cos(\Theta)$ et V suit une loi uniforme sur $[0, 1]$.

Distribution de T_2 :

De façon similaire, on peut calculer la densité de $\sin(\Theta)$, puis on peut prouver que T_2 et V sont indépendantes et que T_2 suit la même distribution que $\sin(\Theta)$.

c) Distribution de (X, Y) ?

$S = F^{-1}(V)$ avec $V \sim \mathcal{U}([0, 1])$ et F^{-1} l'inverse de la fonction de répartition d'une loi de Rayleigh de paramètre 1 (d'après la question 2.). Donc S suit une loi de Rayleigh de paramètre 1 d'après le théorème de la transformée inverse.

Comme les variables aléatoires T_1 et T_2 sont indépendantes de V , elles sont indépendantes de S . D'après la question 1., $\boxed{X \text{ et } Y \text{ sont indépendantes}}$ et $\boxed{X \text{ et } Y \sim \mathcal{N}(0, 1)}$.

d) Le nombre moyen d'étapes dans la boucle revient à regarder la probabilité de se trouver dans un disque de rayon 1 sachant qu'on est uniformément dans $[-1, 1]^2$. En faisant le ratio des surfaces, on trouve que cette probabilité est $\frac{\pi}{4}$.

On note C la variable aléatoire du nombre de coups au bout duquel on sort de la boucle. Elle suit une loi géométrique, pour $n \geq 1$:

$$P(C = n) = \frac{\pi}{4} \left(1 - \frac{\pi}{4}\right)^{n-1}$$

On calcule donc l'espérance d'une loi géométrique :

$$\begin{aligned} \mathbb{E}[C] &= \sum_{n=1}^{+\infty} nP(C = n) \\ &= \sum_{n=1}^{+\infty} \frac{n\pi}{4} \left(1 - \frac{\pi}{4}\right)^{n-1} \\ &= \frac{\pi}{4} \frac{1}{\left(\frac{\pi}{4}\right)^2} && \text{par (2).} \\ &= \boxed{\frac{4}{\pi}} \end{aligned}$$

Justification de (2) :

Notons $f_n(q) = \sum_{k=0}^n q^k$. Pour $0 < q < 1$, on reconnaît une série géométrique de raison q :

$$f_n(q) = \frac{1 - q^{n+1}}{1 - q}$$

Dérivons par rapport à la variable q :

$$\sum_{k=1}^n kq^{k-1} = \frac{-(n+1)q^n(1-q) + (1-q^{n+1})}{(1-q)^2}$$

Par croissance comparée, il est clair qu'on a :

$$\lim_{n \rightarrow +\infty} \sum_{k=1}^n kq^{k-1} = \frac{1}{(1-q)^2} \quad (2)$$

Exercice 2 Invariant distribution

Rappel (Noyau de transition)

Soit \mathcal{X} l'ensemble des états d'une chaîne de Markov, $P : (\mathcal{X} \times \mathcal{X}) \rightarrow \mathbb{R}$ est une matrice de transition si :

$$\forall (x, y) \in (\mathcal{X} \times \mathcal{X}), P(x, y) \geq 0 \quad \text{et} \quad \sum_y P(x, y) = 1 \quad \forall x \in \mathcal{X}$$

En particulier, $\forall x \in \mathcal{X}, Q(y) = P(x, y)$ est une loi de probabilités sur \mathcal{X} .

Par extension on définit le noyau de transition pour $A \subset \mathcal{X}$:

- $\forall x \in \mathcal{X}, A \mapsto P(x, A)$ est une loi de probabilité.
- $\forall A \subset \mathcal{X}, x \mapsto P(x, A)$ est mesurable.

Et on définit aussi l'application de P sur les fonctions ou mesures :

$$\begin{cases} Pf : \mathcal{X} \rightarrow \mathbb{R}^+ \\ x \mapsto \sum_{y \in \mathcal{X}} P(x, y) f(y) \end{cases} \quad \begin{cases} \mu P : \mathcal{X} \rightarrow \mathbb{R}^+ \\ y \mapsto \sum_{x \in \mathcal{X}} P(x, y) \mu(x) \end{cases}$$

1. On note $Q = \{\frac{1}{m}, m \in \mathbb{N}^*\}$. Le noyau de transition de (X_n) est la distribution de $X_{n+1}|X_n$. Si on peut montrer 3 pour toute fonction h continue et bornée, on aura identifié le noyau de transition de (X_n) par le théorème d'identification des lois.

$$\mathbb{E}[h(X_{n+1})|X_n] \sim \int_{\mathbb{R}} h(y) P(x, dy) \tag{3}$$

Si $x \notin Q$:

$$\begin{aligned} \mathbb{E}[h(X_{n+1})|X_n] &= \int_{\mathbb{R}} h(y) f_{X_{n+1}|X_n}(y) dy \\ &= \int_{\mathbb{R}} h(y) \mathbb{1}_{\{[0,1]\}}(y) dy \end{aligned} \quad \text{par l'énoncé.}$$

Donc $P(x, A) = \int_A P(x, dy) = \boxed{\int_{A \cap [0,1]} dy}$.

Si $x \in Q$:

On note $B_m \sim \mathcal{B}(\frac{1}{m^2})$.

$$\begin{aligned} \mathbb{E}[h(X_{n+1})|X_n] &= \mathbb{E}[h(X_{n+1})|X_n, B_m = 0]P(B_m = 0) + \mathbb{E}[h(X_{n+1})|X_n, B_m = 1]P(B_m = 1) \\ &= h\left(\frac{1}{m+1}\right) \left(1 - \frac{1}{m^2}\right) + \frac{1}{m^2} \int_{A \cap [0,1]} h(y) dy \end{aligned}$$

D'où :

$$\begin{aligned}
 P(x, A) &= \int_A P(x, dy) \\
 &= \boxed{(1 - x^2) \delta_{\frac{1}{m+1}}(A) + x^2 \int_{A \cap [0,1]} dy} \quad \text{avec } x^2 = \frac{1}{m^2}
 \end{aligned}$$

On a donc :

$$P(x, A) = \begin{cases} (1 - \frac{1}{m^2}) \delta_{\frac{1}{m+1}}(A) + \frac{1}{m^2} \int_{A \cap [0,1]} dy & \text{si } x = \frac{1}{m}. \\ \int_{A \cap [0,1]} dy & \text{sinon.} \end{cases}$$

2. On note $\pi \sim \mathcal{U}([0, 1])$, montrons que $\pi P = \pi$.

Soit A une partie de \mathbb{R} .

$$\begin{aligned}
 \pi P(A) &= \int_{\mathbb{R}} P(x, A) \pi(x) \\
 &= \int_{[0,1]} P(x, A) dx && \text{car } \pi \text{ uniforme.} \\
 &= \int_{[0,1] \cap Q} P(x, A) dx + \int_{[0,1] \cap \bar{Q}} P(x, A) dx && \text{par la relation de Chasles.} \\
 &= \int_{[0,1] \cap \bar{Q}} P(x, A) dx && \text{car } Q \text{ est de mesure nulle.} \\
 &= \int_{[0,1] \cap A} dt && \text{par la question 1.} \\
 &= \pi(A) && \text{car } \pi \text{ est uniforme sur } [0, 1].
 \end{aligned}$$

On a bien $\boxed{\pi P = \pi}$.

3. Soit $x \notin Q$. Calculons $P^n f(x)$ pour tout $n \geq 1$ et $\lim_{n \rightarrow +\infty} P^n f(x)$ en fonction de $\int f(t) \pi(t) dt$. Nous procédons par récurrence.

Soit la propriété $\mathcal{P}(n) : P^n f(x) = \int_0^1 f(y) dy$.

Initialisation :

$$P f(x) = \mathbb{E}[f(X_1) | X_0 = x] = \int_0^1 f(y) dy \quad \text{car } x \notin Q.$$

Donc $\mathcal{P}(1)$ est vraie.

Récurrence :

Soit $n \in \mathbb{N}^*$, supposons $\mathcal{P}(n)$. Montrons $\mathcal{P}(n+1)$:

$$\begin{aligned}
P^{n+1}f(x) &= PP^n f(x) \\
&= \int_0^1 \left(\int_0^1 f(y) dy \right) dx && \text{par } \mathcal{P}(n) \text{ et car } x \notin Q. \\
&= \int_0^1 f(y) dy && (\text{intégration d'une constante}).
\end{aligned}$$

On a bien $\mathcal{P}(n+1)$.

Conclusion :

On a bien $\boxed{\mathcal{P}(n) \text{ pour tout } n \in \mathbb{N}^*}$.

On s'intéresse maintenant à $\lim_{n \rightarrow +\infty} P^n f(x)$:

$$\begin{aligned}
\lim_{n \rightarrow +\infty} P^n f(x) &= \lim_{n \rightarrow +\infty} \int_0^1 f(y) dy && \text{par ce qui précède.} \\
&= \int_0^1 f(y) dy && \text{car le terme est indépendant de } n. \\
&= Pf(x) \\
&= \pi Pf(x) && \text{par la question 2.} \\
&= \boxed{\int_0^1 f(y) \pi(y) dy}
\end{aligned}$$

4. a) Soit $x = \frac{1}{m}$ avec $m \geq 2$. Nous procédons par récurrence.

Soit la propriété $\mathcal{P}(n) : P^n(\frac{1}{m}, \frac{1}{n+m}) = \prod_{k=1}^n \left(1 - \frac{1}{(m+k-1)^2}\right)$.

Initialisation :

$$\begin{aligned}
P\left(\frac{1}{m}, \frac{1}{m+1}\right) &= \frac{1}{m^2} \int_{\{\frac{1}{m+1}\} \cap [0,1]} dt + \left(1 - \frac{1}{m^2}\right) \delta_{\frac{1}{m+1}} \left(\left\{\frac{1}{m+1}\right\}\right) && \text{par la question 1.} \\
&= 1 - \frac{1}{m^2}
\end{aligned}$$

Donc $\mathcal{P}(1)$ est vraie.

Récurrence :

Soit $n \in \mathbb{N}^*$, supposons $\mathcal{P}(n)$. Montrons $\mathcal{P}(n+1)$:

$$\begin{aligned}
P^{n+1}\left(\frac{1}{m}, \frac{1}{m+n+1}\right) &= P\left(\frac{1}{m+n}, \frac{1}{m+n+1}\right) P^n\left(\frac{1}{m}, \frac{1}{m+n}\right) \\
&\quad + \left(1 - P^n\left(\frac{1}{m}, \frac{1}{m+n}\right)\right) \int_{\{\frac{1}{m+n+1}\} \cap [0,1]} dt \\
&= \left(1 - \frac{1}{(m+n)^2}\right) \prod_{k=1}^n \left(1 - \frac{1}{(m+k-1)^2}\right) \\
&\quad + 0 \\
&= \prod_{k=1}^{n+1} \left(1 - \frac{1}{(m+k-1)^2}\right)
\end{aligned}$$

On a bien $\mathcal{P}(n+1)$.

Conclusion :

Pour tout $n \in \mathbb{N}^*$, $\boxed{P^n\left(\frac{1}{m}, \frac{1}{n+m}\right) = \prod_{k=1}^n \left(1 - \frac{1}{(m+k-1)^2}\right)}$.

On peut développer l'expression précédente :

$$\begin{aligned}
P^n\left(\frac{1}{m}, \frac{1}{n+m}\right) &= \prod_{k=1}^n \left(1 - \frac{1}{(m+k-1)^2}\right) \\
&= \prod_{k=1}^n \left(\frac{(m+k-1)^2 - 1}{(m+k-1)^2}\right) \\
&= \prod_{k=1}^n \left(\frac{(m+k-2)(m+k)}{(m+k-1)^2}\right) \\
&= \prod_{k=1}^n \left(\frac{m+k-2}{m+k-1}\right) \prod_{k=1}^n \left(\frac{m+k}{m+k-1}\right) \\
&= \frac{m-1}{m+n-1} \times \frac{m+n}{m} \quad \text{en simplifiant les termes qui s'annulent.} \\
&= \boxed{\frac{m-1}{m} \times \frac{m+n}{m+n-1}}
\end{aligned}$$

b) Par la question précédente, il est clair que :

$$\lim_{n \rightarrow +\infty} P^n\left(\frac{1}{m}, \frac{1}{n+m}\right) = \frac{m-1}{m}$$

On note $A = \bigcup_{q \in \mathbb{N}} \left\{ \frac{1}{m+q+1} \right\}$. Il est clair que pour des valeurs de m élevées, on a $\frac{m-1}{m} \approx 1$ et on est presque sûr de se trouver dans A asymptotiquement. En revanche, pour des valeurs de m faibles, on a des chances de sortir de A , et par les mêmes arguments que précédemment (la mesure de A est nulle), on n'a aucune chance de revenir dans A . On distingue donc deux cas :

- On sort de A avec probabilité $\frac{1}{m}$. Dans ce cas :

$$\lim_{n \rightarrow +\infty} P^n(x, A) = \pi([0, 1])$$

- On reste dans A avec probabilité $\frac{m-1}{m}$. Dans ce cas on n'a pas $\lim_{n \rightarrow +\infty} P^n(x, A) = \pi(A)$ puisqu'on a montré que les probabilités de transitions entre les états $\frac{1}{m+n}$ et $\frac{1}{m+n+1}$ tendent vers 1.

Donc d'une façon générale, $\lim_{n \rightarrow +\infty} P^n(x, A) \neq \pi(A)$.

Exercice 3 Stochastic Gradient Learning in Neural Networks

Les réponses aux questions sont dans le Jupyter Notebook.